

# APA Modulo 1 Lezione 9

Elena Zucca

26 marzo 2020

# Tecniche algoritmiche: ripasso divide-et-impera

## Schema generale

```
div_imp(P) //dim P = n
  if (n < n0) risolvi P direttamente
  else
    dividi P in sottoproblemi P1, ... , Pk di dim < n
    div_imp (P1)
    ...
    div_imp (Pk)
    costruisci la soluzione di P
    a partire dalle soluzioni di P1, ... , Pk
```

# Correttezza e complessità

- correttezza si basa su **induzione forte**:
  - l'algoritmo è corretto sui problemi base
  - assumendo che sia corretto sui sottoproblemi (di dimensione **minore**) lo è sul problema P
- analisi complessità si basa su risolvere **relazioni di ricorrenza**

## Esempi visti: ricerca binaria ricorsiva

```
binary_search(x,a,inf,sup)
  if (inf <= sup)
    mid = (inf + sup)/2
    if (x < a[mid]) return binary_search(x,a,inf,mid-1)
    else if (x > a[mid])
      return binary_search(x,a,mid+1,sup)
    else return true
  return false
```

- problema di partenza: ricerca in  $(0, n - 1)$   
sottoproblemi: ricerca in  $(inf, sup)$ ,  $0 \leq inf, sup \leq n - 1$
- base: nessun elemento ( $inf > sup$ )
- passo induttivo: ricerca in  $(inf, mid-1)$  oppure  $(inf+1, sup)$   
(dim.  $n/2$ )
- relazione di ricorrenza:  $T(n) = 1 + T(n/2)$

# Esempi visti: Hanoi

```
hanoi(n, source, aux, dest)
    if (n = 1) move(source, dest)
    else
        hanoi(n-1, source, dest, aux)
        move(source, dest)
        hanoi(n-1, aux, source, dest)
```

- problema di partenza: Hanoi  $n$   
sottoproblemi: Hanoi  $k$ ,  $1 \leq k \leq n$
- base: un elemento
- passo induttivo: Hanoi  $n - 1$
- relazione di ricorrenza:  $T(n) = 1 + 2T(n - 1)$

# Programmazione dinamica

## Esempio introduttivo: numeri di Fibonacci

$$fib_0 = 0$$

$$fib_1 = 1$$

$$fib_{i+1} = fib_i + fib_{i-1}$$

$0, 1, 1, 2, 3, 5, 8, \dots$

- la definizione induttiva fornisce ovvio algoritmo ricorsivo (divide-et-impera)
- relazione di ricorrenza:

$$T(n) = T(n-1) + T(n-2) + \Theta(1)$$

## Risolviamo:

Dato che ovviamente  $T(n+1) > T(n)$  per  $n > 2$ ,

$$T(n) > 2T(n-2) + 1$$

Risolviamo:

$$T(n) > 2(2T(n-4) + 1) + 1 = 2^2 T(n-4) + 2^1 + 2^0 > \dots > 2^i T(n-2i) + 2^{i-1} + \dots + 2^1 + 2^0$$


*(ultimo termine per  $i = k$  se  $n = 2k$ )*

$$> 2^k + \dots + 2^0 = 2^{k+1} - 1 = 2^{\frac{n}{2}+1} - 1$$

l'albero delle chiamate ricorsive è infatti simile a quello per le torri di Hanoi ma con  $n/2$  livelli



- si ha quindi un algoritmo **esponenziale**
- infatti, l'algoritmo ricorsivo ricalcola inutilmente i risultati parziali, come risulta evidente provando a scrivere l'albero delle chiamate.



- tuttavia, è banale scrivere un algoritmo iterativo **lineare** con la tecnica della *programmazione dinamica*:

```
Fibonacci(n)
  fib = array con indici 0..n-1
  fib[0] = 0
  fib[1] = 1
  for (i=2; i < n; i++)
    fib[i] = fib[i-1]+ fib[i-2]
  return fib[n-1]
```

# Caratteristiche della programmazione dinamica

NB: “programmazione” nel senso di *pianificazione*, come per la programmazione lineare

- come in divide et impera:
  - si ricava la soluzione di un problema dalle soluzioni di sottoproblemi più piccoli
  - correttezza per induzione aritmetica completa sulla dimensione dei problemi
- Ma:
  - **bottom-up** invece di top-down
  - per prima cosa si risolvono i sottoproblemi base
  - poi via via i successivi fino a quello richiesto, **memorizzando** i risultati intermedi
  - conveniente se **un sottoproblema viene utilizzato per risolvere molti problemi di livello superiore**
  - è possibile calcolarne la soluzione una volta sola, e quindi l'approccio risulta vantaggioso

# Longest Common Subsequence (LCS)

- problema: date due sequenze trovare una sottosequenza comune di lunghezza massima (individuata da una sequenza di coppie di indici)
- esempi reali: biologia (trovare la più lunga sottosequenza comune a due sequenze di DNA), sicurezza informatica (individuare, in un log costituito da una sequenza di comandi, le sottosequenze che indicano la presenza di un possibile attacco al sistema), etc.

## Esempio

AGCCGGATCGAGT  
TCAGTACGTTA

una sottosequenza comune di lunghezza massima è:

AGCGTA

Un'altra sottosequenza comune di lunghezza massima, per le stesse due sequenze, è:

AGTCGA


Infatti:

AGCCGGATCGAGT  
TCAGTACGTTA

# Come rappresentiamo una sottosequenza?

come sequenza di coppie di indici

La più lunga sottosequenza comune di:



è la sottosequenza comune **AGCGTA** indicata da:

[ (0, 2), (1, 3), (2, 6), (4, 7), (7, 8), (10, 10) ]

# Algoritmo “brute force”

- algoritmo ingenuo: date  $s_1$  lunga  $m$  ed  $s_2$  lunga  $n$
- genero tutte le sottosequenze di  $s_1$   
controllando se ognuna è sottosequenza di  $s_2$   
tenendo traccia della lunghezza max
- le sottosequenze di  $s_1$  sono  $2^m$
- per ognuna occorrono nel caso peggiore  $n$  passi per controllare se è anche sottosequenza di  $s_2$
- la complessità è quindi  $n \times 2^m$
- esponenziale!

# Formulazione induttiva della soluzione: base

- siano  $X[1..m]$  e  $Y[1..n]$  sono le due sequenze
- sottoproblema  $LCS(i, j)$ : sottosequenza comune di lunghezza massima tra i prefissi  $X[1..i]$  e  $Y[1..j]$ .
- problema di partenza  $LCS(m, n)$
- base della definizione induttiva: una delle due sequenze è vuota

$$LCS(0, j) = [ ] \text{ per } 0 \leq j \leq n$$

$$LCS(i, 0) = [ ] \text{ per } 0 \leq i \leq m$$



# Passo induttivo

- esaminiamo  $X(i)$  e  $Y(j)$ , due casi:
  - se  $X(i) = Y(j)$   
le sottosequenze comuni di  $X[1..i]$  e  $Y[1..j]$  sono tutte quelle di  $X[1..i-1]$  e  $Y[1..j-1]$ , e quelle ottenute aggiungendo in fondo a una di queste la coppia  $(i, j)$   
quindi  $LCS(i, j) = LCS(i-1, j-1) \cdot (i, j)$

## Graficamente

- **caso 1:**  $X[i] = Y[j]$



Come si vede chiaramente dal disegno,

se  $LCS(i-1, j-1) = [ (i_0, j_0), (i_1, j_1), \dots (i_k, j_k) ]$

allora  $LCS(i, j) = [ (i_0, j_0), (i_1, j_1), \dots (i_k, j_k), (i, j) ]$ .

# Passo induttivo

- se  $X(i) \neq Y(j)$   
le sottosequenze comuni di  $X[1..i]$  e  $Y[1..j]$  **non** possono includere la coppia  $(i, j)$   
sono quindi sottosequenze comuni di  $X[1..i - 1]$  e  $Y[1..j]$ , oppure  
sottosequenze comuni di  $X[1..i]$  e  $Y[1..j - 1]$   
quindi  $LCS(i, j)$  è la più lunga fra  $LCS(i - 1, j)$  e  $LCS(i, j - 1)$

## Graficamente

l'elemento finale di una sottosequenza comune non può essere la coppia  $(i, j)$ , ma può essere una coppia  $(i, j')$  con  $j' < j$ , oppure  $(i', j)$  con  $i' < i$ . Esempio:



## Riassumendo:

- base

$$LCS(0, j) = [ ] \text{ per } 0 \leq j \leq n$$

$$LCS(i, 0) = [ ] \text{ per } 0 \leq i \leq m$$

- passo induttivo

*per  $i \neq 0, j \neq 0$ :*

$$LCS(i, j) = LCS(i-1, j-1) \cdot (i, j) \text{ se } X(i) = Y(j)$$

$$LCS(i, j) = \max(LCS(i-1, j), LCS(i, j-1)) \text{ altrimenti}$$

- si noti che in questo caso la dimensione del problema è una coppia di numeri, che ordinamento consideriamo?
- prodotto**, ossia  $(i, j) \leq (i', j')$  se  $i \leq i'$  e  $j \leq j'$

## Se ci interessa la lunghezza:

- base

$$LCS(0, j) = 0 \text{ per } 0 \leq j \leq n$$

$$LCS(i, 0) = 0 \text{ per } 0 \leq i \leq m$$

- passo induttivo

*per  $i \neq 0, j \neq 0$ :*

$$LCS(i, j) = LCS(i - 1, j - 1) + 1 \text{ se } X(i) = Y(j)$$

$$LCS(i, j) = \max(LCS(i - 1, j), LCS(i, j - 1)) \text{ altrimenti}$$

# Relazione di ricorrenza

- $T(n, m) = T(n - 1, m) + T(n, m - 1) + 1$
- considerando la somma  $k = n + m$  si ha  
 $T(k) = 2T(k - 1) + 1$  relazione di ricorrenza delle torri di Hanoi
- si può però dare un algoritmo migliore con la programmazione dinamica
- infatti ogni sottoproblema è utilizzato nella soluzione di più problemi di dimensione superiore

# Algoritmo di programmazione dinamica

- matrice LCS con  $m+1$  righe ed  $n+1$  colonne
- prima riga e colonna per la sequenza vuota, di lunghezza 0
- si riempie riga per riga (o colonna per colonna)
- la casella  $LCS(m,n)$  conterrà la soluzione
- in ogni casella non serve tutta la LCS ma basta lunghezza e simbolo convenzionale per tre casi, per esempio:
  - se si ha lo stesso carattere su riga e colonna ↖ e lunghezza + 1
  - altrimenti, ↑ o ← e lunghezza uguale
- la LCS si ricostruisce all'indietro
- se si è interessati solo alla lunghezza, basta costruire la matrice delle lunghezze




# Esempio

		A	T	C	B	A	B
	0	0	0	0	0	0	0
B	0	0↑	0↑	0↑	↖ 1	← 1	↖ 1
A	0	↖ 1	← 1	← 1	↑ 1	↖ 2	← 2
C	0	↑ 1	↑ 1	↖ 2	← 2	↑ 2	↑ 2
A	0	↖ 1	↑ 1	↑ 2	↑ 2	↖ 3	← 3
T	0	↑ 1	↖ 2	↑ 2	↑ 2	↑ 3	↑ 3
B	0	↑ 1	↑ 2	↑ 2	↖ 3	↑ 3	↖ 4
A	0	↑ 1	↑ 2	↑ 2	↑ 3	↖ 4	↑ 4

- per calcolare  $LCS(i, j)$  basta conoscere tre caselle contigue  
 $LCS(i-1, j-1)$ ,  $LCS(i-1, j)$ ,  $LCS(i, j-1)$
- viceversa ogni casella può essere utilizzata per calcolarne altre tre

## Graficamente


- Per trovare la  $LCS(i, j)$  basta conoscere le tre LCS contigue, cioè:  $LCS(i-1, j-1)$ ,  $LCS(i-1, j)$ ,  $LCS(i, j-1)$ .



## Graficamente

Reciprocamente, ogni  $LCS(i, j)$  può essere utilizzato per il calcolo di tre altri LCS:

$$LCS(i+1, j+1), LCS(i, j+1), LCS(i+1, j).$$



# Implementazione

- dato che basta memorizzare solo lunghezza e riferimento, lo spazio necessario è  $O(mn)$
- usiamo per semplicità due matrici: la matrice L delle lunghezze e la matrice R dei riferimenti (coppie di indici, oppure tre valori convenzionali)

# Pseudocode

```
for (i = 0; i <= m; i++) L[i,0] = 0
for (j = 0; j <= n; j++) L[0,j] = 0

for (i = 1; i <= m; i++)
  for (j = 1; j <= n; j++)
    if (X[i] = Y[j])
      L[i,j] = L[i-1,j-1] + 1; R[i,j] = ↖
    else if (L[i,j-1] > L[i-1,j])
      L[i,j] = L[i,j-1]; R[i,j] = ←
    else L[i,j] = L[i-1,j]; R[i,j] = ↑
```

# Osservazioni

- per ricostruire la LCS si parte da  $(m, n)$  e si va all'indietro seguendo le frecce, in corrispondenza di ogni freccia diagonale si ha un elemento della sequenza (scrivere l'algoritmo per esercizio)
- complessità temporale  $T(m, n) = \Theta(mn)$   
costruzione di matrici  $m \times n$
- assumendo come al solito  $m \sim n$ , l'algoritmo è quadratico molto meglio dell'algoritmo ingenuo esponenziale
- complessità spaziale  $S(m, n) = \Theta(mn)$   
memorizzazione di matrici  $m \times n$
- si può ottimizzare lo spazio ottenendo complessità lineare